

Pulsevera

Laporan Teknis Komprehensif

Deteksi Dini Risiko Penyakit Jantung Berbasis Kecerdasan Buatan

Proyek	CC26-PRU439 · DBS Foundation Coding Camp 2026
Dataset	CDC BRFSS 2022 — 445.132 responden
Model Final	Deep Learning + SMOTE @ Threshold 0.23
Akurasi	85.76%
Recall (Positif)	71.15%
ROC-AUC	0.8812
Tanggal Laporan	02 June 2026

"Jantungmu, Cerita Masa Depanmu."
Pulsevera — Early Cardiovascular Risk Detection for Everyone.

Daftar Isi

1. Executive Summary
2. Problem Discovery & Business Context
3. Dataset — CDC BRFSS 2022
4. Data Wrangling & Preprocessing
5. Exploratory Data Analysis
6. Feature Engineering
7. A/B Testing — Validasi Hipotesis
8. ML Baseline Modeling
9. Deep Learning — Arsitektur & Training
10. Evaluasi Model & Threshold Tuning
11. SHAP Interpretability
12. Arsitektur Sistem & Deployment
13. Limitasi & Rencana ke Depan

1. Executive Summary

Pulsevera adalah aplikasi web berbasis Kecerdasan Buatan yang memungkinkan siapa pun melakukan screening awal risiko penyakit jantung dalam kurang dari dua menit, tanpa memerlukan latar belakang medis atau kunjungan ke fasilitas kesehatan. Laporan ini mendokumentasikan seluruh pipeline sains data — mulai dari eksplorasi dataset, rekayasa fitur, pengujian hipotesis, pemodelan, hingga interpretabilitas dan integrasi ke sistem produksi.

Temuan Kunci:

Dataset: CDC BRFSS 2022 dengan 445.132 sampel; target HadHeartAttack memiliki class imbalance ekstrem (5,6% positif). Empat strategi digunakan: SMOTE, class_weight balanced, Focal Loss, dan threshold tuning.

Model Final: Deep Learning (Dense 256-128-64) + SMOTE, dilatih dengan Focal Loss ($\gamma=2.0$, $\alpha=0.25$) dan EarlyStoppingByRecall. Threshold operasional 0.23 dipilih sebagai sweet spot yang memenuhi kedua target: Accuracy $\geq 85\%$ dan Recall $\geq 70\%$.

Performa: Accuracy 85.76%, Recall 71.15%, Precision 24.14%, F1 36.05%, ROC-AUC 0.8812. Model mengungguli Random Forest (RF) dalam Recall (71% vs 44%) dan ROC-AUC (0.88 vs 0.85) meskipun RF memiliki accuracy lebih tinggi (91%).

Feature Engineering: 6 fitur baru dibuat: BMI, LifestyleRiskScore (0–5), IsObese, IsSleepDeprived, IsActiveSmoker, HasChronicCondition. LifestyleRiskScore masuk top-20 global SHAP importance.

A/B Testing: 4 hipotesis epidemiologis divalidasi secara statistik (semua signifikan, $p < 0.001$). Aktivitas fisik, BMI, merokok, dan pola tidur terbukti berhubungan dengan risiko serangan jantung.

Interpretabilitas: SHAP TreeExplainer digunakan untuk atribusi fitur per instance dan global importance. GeneralHealth, AgeCategory, dan HadAngina adalah kontributor utama prediksi.

Sistem: Three-layer architecture: React + Vite frontend, Express.js proxy, FastAPI ML API. Inference time $\pm 350\text{ms}$ termasuk preprocessing, model forward pass, SHAP matching, dan Gemini recommendation.

2. Problem Discovery & Business Context

2.1 Skala Masalah

Penyakit kardiovaskular (CVD) adalah penyebab kematian nomor satu di Indonesia dan dunia. Data epidemiologis dari berbagai sumber internasional dan nasional mengkonfirmasi skala dan urgensi masalah ini:

Statistik	Angka	Sumber
Kematian CVD per tahun (Indonesia)	~635.000	WHO Global Health Estimates 2023
Serangan jantung pertama yang langsung fatal	40%	AHA Heart Disease Statistics 2024
Biaya perawatan CVD per episode	Rp 30–150 juta	BPJS Kesehatan Annual Report 2022
Penderita yang tidak menyadari risiko	1 dari 3	Riskesdas Biomedis 2019
Proporsi kematian total dari CVD	~17%	Riskesdas 2023

2.2 Tiga Gap yang Pulsevera Isi

Gap 1 — Akses Screening Terbatas

Screening EKG/echocardiogram membutuhkan peralatan khusus (Rp 300K–2,5 juta), tenaga medis spesialis, dan infrastruktur RS tipe B/C ke atas. Di luar Jawa, rasio dokter jantung 1:1,2 juta penduduk — jauh di bawah standar WHO (1:100.000).

Gap 2 — Kesadaran Rendah di Usia Produktif

Generasi muda (25–34 tahun) cenderung merasa "terlalu muda untuk khawatir." Tidak ada tools personal, relevan, dan berbasis data yang tersedia untuk segmen ini. Padahal faktor risiko sudah mulai terbentuk di usia 20-an.

Gap 3 — Tidak Ada Early Warning Digital

40% serangan jantung pertama langsung fatal sebelum sempat ke RS. Tidak ada titik sentuh preventif digital yang personal dan transparan. Gap ini adalah akibat langsung dari Gap 1 dan Gap 2.

2.3 Solusi: Pulsevera

Pulsevera adalah aplikasi web yang memungkinkan screening mandiri dengan mengisi 10 pertanyaan tentang gaya hidup sehari-hari (tidak memerlukan peralatan medis). Output berupa: (1) **Skor Gaya Hidup 0–5** yang actionable, (2) **Estimasi Probabilitas Risiko** berbasis model DL, (3) **Rekomendasi personal** via Gemini AI. Seluruh proses selesai dalam kurang dari dua menit, gratis, dan tidak menyimpan data pengguna.

Aspek	Klinik/RS Konvensional	Pulsevera
Akses	Jadwal dokter, antrian, biaya	Browser, gratis, 24/7
Waktu	1–3 jam	< 2 menit
Output	Angka klinis (EKG, lipid panel)	Skor gaya hidup + rekomendasi actionable
Personalisasi	Standar (form umum)	AI-generated per profil
Bahasa	Teknis medis	Bahasa awam, mudah dipahami
Privasi	Data disimpan di rekam medis	Tidak disimpan, real-time inference

3. Dataset — CDC BRFSS 2022

3.1 Profil Dataset


Behavioral Risk Factor Surveillance System (BRFSS) adalah survei telepon rutin yang dijalankan oleh Centers for Disease Control and Prevention (CDC) Amerika Serikat. Dataset tahun 2022 dipilih karena: (1) skala besar yang cukup untuk melatih model DL yang stabil, (2) otoritas sumber yang diakui WHO sebagai benchmark global, (3) cakupan fitur gaya hidup yang relevan secara universal.

Atribut	Detail
Jumlah Sampel	445.132 responden
Jumlah Fitur (asli)	40 variabel perilaku kesehatan
Target Variabel	HadHeartAttack (binary: 0/1)
Distribusi Target	5,6% positif (24.971 kasus) — 94,4% negatif
Sumber	CDC BRFSS 2022 via Kaggle (dataset publik, dapat diverifikasi)
Tahun Data	2022 (survei terakhir yang tersedia publik saat proyek dimulai)
Lisensi	Public Domain — CC0

3.2 Distribusi Target

Class imbalance 5,6% positif merupakan tantangan utama dalam proyek ini. Visualisasi distribusi target menunjukkan dominasi kelas negatif yang signifikan, yang jika tidak ditangani akan menyebabkan model bias ke prediksi "tidak berisiko".

Distribusi Target Variable: HadHeartAttack



Gambar 3.1. Distribusi target HadHeartAttack — 94,4% negatif, 5,6% positif.

3.3 Pemilihan Fitur untuk Form Input

Dari 40+ kolom dataset, 10 fitur dipilih untuk form input berdasarkan kriteria: (1) dapat diketahui sendiri oleh pengguna tanpa peralatan medis, (2) memiliki SHAP importance yang signifikan, (3) meminimalkan missing value dari pengguna awam.

#	Fitur Form	Kolom Dataset	SHAP Global Rank	Dapat Dimodifikasi?
1	Kondisi Kesehatan Umum	GeneralHealth	#1 (0.111)	Indikator keseluruhan
2	Usia	AgeCategory	#3 (0.076)	Tidak (non-modifiable)
3	Diabetes	HadDiabetes	#5 (0.058)	Dapat dikelola
4	Konsumsi Alkohol	AlcoholDrinkers	#6 (0.048)	Ya
5	Aktivitas Fisik	PhysicalActivities	#8 (0.039)	Ya
6	Jam Tidur	SleepHours	#15 (0.016)	Ya
7	Status Merokok	SmokerStatus	~#20	Ya
8	Jenis Kelamin	Sex	#16 (0.013)	Tidak
9	Tinggi Badan	HeightInMeters	#12 (0.019)	Input BMI
10	Berat Badan	WeightInKilograms	#18 (0.011)	Input BMI

Catatan: Fitur klinis dengan SHAP tinggi (HadAngina #4, HadStroke) tidak ditanyakan karena pengguna awam sering tidak mengetahuinya — nilai di-default ke 0 (tidak ada riwayat), yang merupakan pendekatan konservatif dan aman.


4. Data Wrangling & Preprocessing

Pipeline data wrangling dirancang untuk menghasilkan dataset bersih dan konsisten yang dapat direproduksi. Semua langkah didokumentasikan dalam notebooks/01_data_wrangling.ipynb.

4.1 Langkah-Langkah Preprocessing

Langkah	Aksi	Alasan
Duplikat	Drop 11 baris duplikat identik	Menghindari bias training dari data identik
Missing Values	Imputasi median (numerik), modus (kategorikal)	Preservasi distribusi; BRFSS sudah bersih (~0.3% missing)
BMI Capping	Cap BMI ke [14.51, 40.91] (1st–99th percentile)	Menghilangkan outlier ekstrem yang tidak medis-valid
Encoding	One-hot encoding untuk SmokerStatus & AgeCategory; binary encoding untuk Yes/No	Menggunakan semua fitur kategorikal ke numerik
Scaling	StandardScaler (fit pada X_train, transform X_Test)	Sensitif terhadap skala fitur; scaler disimpan sebagai scaler.pkl
Train/Test Split	80/20 stratified split; random_state=42	Preservasi distribusi class imbalance di kedua set

4.2 Distribusi Numerik Sebelum Cleaning



Gambar 4.1. Distribusi fitur numerik sebelum preprocessing — tampak outlier pada BMI dan SleepHours.


4.3 Split Dataset Final

Set	Jumlah Sampel	Proporsi Positif	Keterangan
X_train	356.105	5,63%	Digunakan untuk training + SMOTE
X_test	89.027	5,64%	Hold-out; tidak pernah dilihat selama training
Total	445.132	5,64%	Stratified split mempertahankan rasio class

5. Exploratory Data Analysis


EDA dilakukan untuk menjawab 5 pertanyaan bisnis utama yang relevan dengan konteks deteksi dini risiko jantung. Seluruh analisis tersedia di `notebooks/02_eda.ipynb`.

5.1 Distribusi Target & Korelasi Fitur




Gambar 5.1. Heatmap korelasi antar fitur. GeneralHealth dan AgeCategory menunjukkan korelasi tertinggi dengan target.

5.2 Q1: Apakah Aktivitas Fisik Berhubungan dengan Risiko Jantung?




Gambar 5.2. Distribusi risiko jantung berdasarkan aktivitas fisik. Kelompok tidak aktif memiliki proporsi serangan jantung lebih tinggi.

5.3 Q2: Bagaimana Distribusi Risiko berdasarkan Usia?




Gambar 5.3. Risiko jantung meningkat drastis pada usia 55+ — justifikasi untuk memasukkan AgeCategory sebagai fitur utama form.

5.4 Q3: Dampak Kombinasi Diabetes dan Merokok




Gambar 5.4. Kombinasi diabetes dan merokok memiliki risiko tertinggi — mendukung keputusan memasukkan kedua fitur ini ke form.

5.5 Q4: Hubungan BMI dengan Risiko Jantung




Gambar 5.5. BMI lebih tinggi berkorelasi positif dengan risiko — mendukung pembuatan fitur *IsObese* dan *LifestyleRiskScore*.

5.6 Q5: Kondisi Kesehatan Umum dan Pola Tidur vs Risiko



Gambar 5.6. Kondisi kesehatan "Buruk/Sangat Buruk" dan sleep deprivation berhubungan dengan risiko lebih tinggi.

5.7 Analisis Multivariat: Usia vs Aktivitas Fisik



Gambar 5.7. Pola multivariat: usia tua + tidak aktif = risiko tertinggi. Menunjukkan interaksi antar fitur yang non-linear.


6. Feature Engineering

Enam fitur baru dibuat berdasarkan domain knowledge medis dan temuan EDA. Semua fitur divalidasi menggunakan SHAP global importance untuk memastikan kontribusi statistik yang nyata, bukan sekadar heuristik. Implementasi tersedia di `notebooks/03_feature_engineering.ipynb`.

6.1 Deskripsi Enam Fitur Baru

Fitur	Formula	Tipe	Justifikasi Medis
BMI	$\text{berat(kg)} / \text{tinggi}^2(\text{m})$	Numerik kontinu	Indeks komposisi tubuh standar WHO; predictor CVD yang tervalidasi
LifestyleRiskScore	Sum 5 flag gaya hidup negatif (0–5)	Ordinal 0–5	Composite indicator; SHAP rank #19 (0.0106) — membuktikan nilai tambah
IsObese	$\text{BMI} \geq 30$	Binary	Flag klinis untuk obesitas; threshold WHO standard
IsSleepDeprived	$\text{SleepHours} < 6$	Binary	NIH: tidur < 6 jam meningkatkan risiko CVD 20–30%
IsActiveSmoker	$\text{SmokerStatus} \in \{\text{Current-some}, \text{Current-every}\}$	Binary	Merokok aktif vs. mantan/tidak pernah — perbedaan klinis signifikan
HasChronicCondition	$\text{diabetes} \vee \text{stroke} \vee \text{angina}$	Binary	Kondisi komorbid yang diketahui memperbesar risiko CVD

6.2 Distribusi LifestyleRiskScore



Gambar 6.1. Distribusi LifestyleRiskScore 0–5. Skor 0 = tidak ada faktor risiko gaya hidup. Korelasi positif dengan target terlihat jelas.

6.3 Top-10 Korelasi Fitur vs Target



Gambar 6.2. Top-10 fitur dengan korelasi tertinggi terhadap HadHeartAttack. LifestyleRiskScore masuk daftar — validasi kontribusi feature engineering.

7. A/B Testing — Validasi Hipotesis Epidemiologis


Empat hipotesis diuji secara statistik untuk memvalidasi bahwa fitur-fitur yang dipilih untuk form input memiliki hubungan yang signifikan dengan target. Pengujian dilakukan di `notebooks/04_ab_testing.ipynb`.

7.1 Ringkasan Hasil A/B Testing

Hipotesis	Uji Statistik	p-value	Effect Size	Kesimpulan
H1: Aktivitas fisik ↓ risiko jantung	Mann-Whitney U	< 0.001	Medium ($\eta^2=0.023$)	TOLAK H0 ✓
H2: BMI tinggi ↑ risiko jantung	Mann-Whitney U	< 0.001	Small-Medium ($\eta^2=0.012$)	TOLAK H0 ✓
H3: Merokok aktif ↑ risiko jantung	Chi-square	< 0.001	Cramér's V = 0.087	TOLAK H0 ✓
H4: Tidur cukup (≥ 6 jam) ↓ risiko	Mann-Whitney U	< 0.05	Small ($\eta^2=0.006$)	TOLAK H0 ✓


Catatan metodologi: Mann-Whitney U dipilih (bukan t-test) karena distribusi tidak memenuhi asumsi normalitas (uji Shapiro-Wilk). Chi-square untuk H3 karena kedua variabel kategorikal. Semua pengujian two-tailed dengan $\alpha=0.05$.

7.2 Visualisasi H1: Aktivitas Fisik vs Risiko



Gambar 7.1. Distribusi *PhysicalActivities* pada kelompok serangan jantung vs tidak. Kelompok dengan aktivitas fisik rendah memiliki proporsi risiko tinggi yang signifikan.

7.3 Visualisasi H2: BMI vs Risiko



Gambar 7.2. Distribusi BMI pada kedua kelompok. Kelompok berisiko memiliki median BMI lebih tinggi secara statistik signifikan.

7.4 Implikasi untuk Model

Semua 4 hipotesis terkonfirmasi signifikan. Ini berarti fitur-fitur yang dimasukkan ke form input (aktivitas fisik, BMI, merokok, tidur) tidak dipilih secara arbitrer — melainkan terbukti secara statistik berpengaruh pada target. Temuan ini juga mendukung desain LifestyleRiskScore sebagai composite indicator yang mencakup semua 4 dimensi gaya hidup yang telah divalidasi.

8. ML Baseline Modeling


Tiga model baseline dilatih dan dievaluasi untuk menentukan benchmark performa sebelum menggunakan Deep Learning. Semua model menggunakan preprocessing yang sama (StandardScaler) dan dievaluasi pada X_test yang sama.

8.1 Perbandingan Model Baseline vs Deep Learning

Model	Accuracy	Recall	Precision	F1	ROC-AUC	Train Time
Logistic Regression	84.2%	64.6%	20.9%	31.6%	0.8310	9s
Decision Tree	82.8%	62.8%	19.0%	29.2%	0.8126	9s
Random Forest	90.9%	44.5%	29.6%	35.6%	0.8461	40s
DL + SMOTE (Final)	85.8%	71.2%	24.1%	36.0%	0.8812	~300s


Kenapa Random Forest (Accuracy 90.9%) tidak dipilih? Accuracy Random Forest tampak tinggi karena model memprediksi mayoritas kelas (tidak berisiko). Recall-nya hanya 44.5% — artinya dari 100 orang berisiko, RF hanya mendeteksi 45. Untuk medical screening, False Negative (gagal deteksi orang berisiko) jauh lebih berbahaya dari False Positive. Deep Learning dengan SMOTE mendeteksi 71 dari 100 orang berisiko sambil mempertahankan Accuracy 85.8% dan ROC-AUC tertinggi.

8.2 Visualisasi Perbandingan Model



Gambar 8.1. Perbandingan metrik semua model. Kolom Recall adalah metrik kritis — DL+SMOTE unggul signifikan.

8.3 ROC Curve Comparison



Gambar 8.2. ROC curve semua model. Area di bawah kurva (AUC) DL+SMOTE = 0.8812, tertinggi di antara semua model.

9. Deep Learning — Arsitektur & Training

9.1 Arsitektur Model

Model menggunakan TensorFlow Functional API dengan arsitektur feedforward yang dirancang khusus untuk data tabular dengan class imbalance ekstrem. Setiap layer tersusun atas Dense → BatchNormalization → Dropout untuk stabilitas training dan regularisasi.

Layer	Konfigurasi	Fungsi
Input	46 fitur (setelah encoding & engineering)	Terima feature vector yang sudah di-scale
Dense 1	256 unit, ReLU	Transformasi high-level — cukup lebar untuk 46 fitur
BatchNorm 1	Momentum=0.99, Epsilon=0.001	Stabilisasi distribusi aktivasi antar batch
Dropout 1	rate=0.30	Regularisasi — mencegah co-adaptation antar neuron
Dense 2	128 unit, ReLU	Kompresi hierarchical — representasi mid-level
BatchNorm 2	Momentum=0.99, Epsilon=0.001	Normalisasi ulang setelah non-linearity
Dropout 2	rate=0.30	Regularisasi ke-2
Dense 3	64 unit, ReLU	Representasi compact — abstraksi high-order
BatchNorm 3	Momentum=0.99, Epsilon=0.001	Normalisasi final sebelum output
Dropout 3	rate=0.30	Regularisasi ke-3
Output	1 unit, Sigmoid	Probabilitas kelas positif $\in [0, 1]$

9.2 Komponen Custom

Focal Loss ($\gamma=2.0$, $\alpha=0.25$): Standard binary cross-entropy memberi bobot sama untuk semua sampel, sehingga model terdistorsi oleh easy negatives (sampel negatif yang mudah diprediksi, mendominasi dataset 94,4%). Focal Loss menambahkan faktor penalti $(1-p_t)^\gamma$ yang secara otomatis mengurangi kontribusi easy examples dan memfokuskan training pada hard examples (positif yang sulit terdeteksi).

EarlyStoppingByRecall (patience=10): Standard EarlyStopping berbasis val_loss atau val_accuracy tidak cocok untuk imbalanced dataset karena keduanya dapat membaik hanya dengan memprediksi lebih banyak negatif. Custom callback ini memonitor val_recall dan menghentikan training jika recall tidak membaik dalam 10 epoch berturut-turut — memastikan model tidak "mundur" ke perilaku prediksi mayoritas.

9.3 Strategi Handling Class Imbalance (4 Lapis)

Strategi	Detail	Efek pada Training
SMOTE sampling_strategy=0.3; oversampling minoritas ke 40%	Realisasi data lebih seimbang; model "melihat" lebih banyak contoh positif	Recall ↑ dari ~30% ke 71.15%
class_weight balanced	class 0: 0.6500, class 1: 2.1667	Loss untuk setiap prediksi positif yang salah dikalikan 2.17x lebih tinggi
Focal Loss	$\gamma=2.0$, $\alpha=0.25$ — penalti lebih besar untuk easy negatives	Focus gradient pada hard-to-classify cases (positif)
Threshold Tuning	Default 0.5 → 0.23 berdasarkan sweep eksperimental	Recall ↑ dari ~30% ke 71.15% tanpa retraining

9.4 Hyperparameter Training

Parameter	Nilai	Justifikasi
Optimizer	Default (yang bisa)	Default (yang bisa) untuk tabular data; lr tidak diturunkan (ReduceLROnPlateau menyebabkan collapse ke all-r
Batch size	512	Keseimbangan antara kecepatan (besar) dan generalisasi (tidak terlalu besar)
Max Epochs	50	EarlyStoppingByRecall biasanya berhenti lebih awal (~25-35 epoch)
Validation split	0.20	Split dari X_train (setelah SMOTE); tidak mencemari test set
Initialization	he_normal	Optimal untuk ReLU activation (Xavier tidak cocok)
Random state	42	Reproduksibilitas: numpy, TensorFlow, SMOTE, sklearn

10. Evaluasi Model & Threshold Tuning

10.1 Hasil Akhir Model DL + SMOTE

Metrik	Nilai	Target Program	Status
Accuracy	85.76%	$\geq 85\%$	LULUS ✓
Recall (Kelas Positif)	71.15%	$\geq 70\%$	LULUS ✓
Precision (Kelas Positif)	24.14%	-	Dibatasi imbalance
F1 Score (Kelas Positif)	36.05%	-	Matematically constrained
ROC-AUC	0.8812	≥ 0.80	LULUS ✓
Threshold Operasional	0.23	Sweet spot	DISEPAKATI ✓


Catatan F1: $F1 < 0.65$ karena class imbalance ekstrem (5.6% positif). Dengan $\text{recall}=0.70$, $F1=0.65$ membutuhkan $\text{precision}\sim 0.61$, yang membutuhkan $\text{ROC-AUC} > 0.95+$ di luar jangkauan dataset CDC BRFSS 2022.

10.2 Justifikasi Threshold 0.23

Threshold default 0.5 berasumsi distribusi prediksi seimbang. Setelah SMOTE mengubah distribusi training, output probabilitas model tidak lagi terkalibrasi ke 0.5. Threshold 0.23 ditemukan melalui eksperimen sistematis (sweep 0.05–0.50 dengan step 0.005) dan disepakati tim sebagai nilai yang memenuhi kedua target program sekaligus:


Threshold	Accuracy	Recall	Keterangan
0.50 (default)	$\sim 91\%$	$\sim 30\%$	Terlalu bias ke mayoritas — 70 dari 100 orang berisiko terlewat
0.23 (operasional)	85.76%	71.15%	Sweet spot: memenuhi $\text{Acc} \geq 85\%$ DAN $\text{Recall} \geq 70\%$
0.10 (terlalu rendah)	$\sim 60\%$	$\sim 90\%+$	Terlalu banyak false positive — tidak praktis

10.3 Kurva Threshold



Gambar 10.1. Kurva metrik vs threshold. Garis hijau putus-putus menunjukkan sweet spot @ 0.23 yang memenuhi target $\text{Acc} \geq 85\%$ dan $\text{Recall} \geq 70\%$.

10.4 Confusion Matrix



Gambar 10.2. Confusion matrix pada threshold 0.23. TP = orang berisiko yang berhasil dideteksi; FN = orang berisiko yang terlewat (paling berbahaya).

11. SHAP Interpretability

SHAP (SHapley Additive exPlanations) digunakan untuk menjelaskan output model secara ilmiah dan transparan. Berbeda dari feature importance tradisional, SHAP memberikan kontribusi per-fitur per-instance dengan arah (positif/negatif), membuatnya menjadi standar de facto untuk explainable AI di industri dan riset.

11.1 Metodologi SHAP


Aspek	Detail
Explainer type	TreeExplainer (efisien untuk tree-based model Random Forest yang digunakan untuk SHAP pre-computation)
Sample size	200 sampel dari training set (representatif, menghemat compute time dari >7000ms → 350ms)
Computation	Pre-computed global importance; bukan per-request real-time (optimasi inference time produksi)
Output format	Mean absolute SHAP value per fitur (global) + top-3 per prediction (instance-level di API)

11.2 Top-10 Global SHAP Importance

Rank	Fitur	SHAP Mean [Value]	Interpretasi
1	GeneralHealth	0.1105	Status kesehatan umum — strongest predictor; mencakup status kesehatan holistik
2	RemovedTeeth	0.0804	Proxy socioeconomic & overall health decay; correlates dengan CVD risk factors
3	AgeCategory	0.0758	Non-modifiable risk factor; risiko meningkat eksponensial setelah usia 55
4	HadAngina	0.0636	Gejala klinis langsung berhubungan dengan CAD (coronary artery disease)
5	HadDiabetes	0.0575	Diabetes meningkatkan risiko CVD 2–4x; masuk form sebagai input utama
6	AlcoholDrinkers	0.0475	Konsumsi alkohol — dual effect (moderate protective, heavy harmful)
7	Race_White only, Non-Hispanic	0.0403	Demografis dataset CDC BRFSS; tidak dimasukkan ke form (US-specific)
8	PhysicalActivities	0.0394	Aktivitas fisik — salah satu modifiable factor paling kuat
9	HIVTesting	0.0318	Proxy akses healthcare dan health-conscious behavior
10	CovidPos	0.0228	Riwayat COVID-19 meningkatkan risiko kardiovaskular jangka panjang


LifestyleRiskScore (fitur engineered) berada di posisi #19 dengan SHAP value 0.0106 — membuktikan bahwa composite feature yang dibuat tim DS memberikan kontribusi statistik nyata.

11.3 SHAP Summary Bar Plot




Gambar 11.1. SHAP global importance (mean absolute value). GeneralHealth mendominasi dengan SHAP 0.111.

11.4 SHAP Beeswarm Plot



Gambar 11.2. SHAP beeswarm — setiap titik = satu sample. Warna merah = nilai fitur tinggi, biru = rendah. Menunjukkan arah dan dispersi pengaruh per fitur.

11.5 SHAP Dependence Plot: GeneralHealth



Gambar 11.3. Dependence plot GeneralHealth. Semakin buruk kondisi kesehatan umum (nilai lebih tinggi = lebih buruk), semakin besar SHAP contribution ke prediksi risiko.

12. Arsitektur Sistem & Deployment

12.1 Three-Layer Architecture

Pulsevera menggunakan arsitektur tiga lapis yang memisahkan concern UI, business logic, dan ML inference. Pemisahan ini penting untuk keamanan (frontend tidak perlu tahu URL ML API), skalabilitas, dan maintainability.

Layer	Teknologi	Port	Tanggung Jawab
Frontend	React 18 + Vite + Tailwind CSS	5173 (dev)	UI, routing, form validation, visualisasi hasil, Axios calls
Backend (Proxy)	Express.js + Node.js	3001 Proxy	aman ke ML API, CORS management, rate limiting, error handling
ML API	FastAPI + Python 3.12	8000	Preprocessing, DL inference, SHAP attribution, Gemini integration

12.2 Alur Data End-to-End

User Browser
↓ (HTTPS POST + JSON form data)
React Frontend (Vite + Tailwind)
↓ (Axios POST /api/predict)
Express.js Backend (proxy + CORS middleware)
↓ (HTTP POST /predict)
FastAPI ML API
■■■ Pydantic validation (46 field types + ranges)
■■■ Preprocessing (one-hot encode + StandardScaler.transform)
■■■ DL Model Inference (keras .predict, batch=1)
■■■ SHAP Attribution (pre-computed lookup by profile)
■■■ Gemini AI Recommendation (prompt engineering + fallback rule-based)
↓ (JSON Response: risk_score, lifestyle, top_factors, recommendations)
React ResultPage (Lifestyle Score + Risk Gauge + Recommendations)

12.3 Inferensi API

Endpoint	Method	Input	Output
/predict	POST	JSON: 10 field dari form user	risk_score, lifestyle{score, habits}, top_risk_factors, recommendations
/health	GET	-	status: ok, model: loaded, inference_ready

12.4 Performa Inferensi

Komponen	Waktu	Keterangan
Preprocessing	~15ms	Pandas + numpy, single sample
DL forward pass	~50ms	Keras .predict, batch=1
SHAP lookup	~5ms	Pre-computed — bukan real-time calculation (dari 7000ms → 5ms)
Gemini API (jika aktif)	~280ms	Network latency ke Gemini API
Total (dengan Gemini)	~350ms	Sangat acceptable untuk web app (target < 1000ms)

Total (tanpa Gemini)	~70ms	Fallback rule-based recommendation
----------------------	-------	------------------------------------

12.5 Target Deployment

Komponen	Platform Target	Tier	Catatan
ML API (FastAPI)	Hugging Face Spaces	Free	Support Python + TensorFlow; 2 CPU, 16GB RAM
Backend (Express)	Railway atau Render	Free tier	Auto-deploy dari GitHub; custom domain tersedia
Frontend (React)	Vercel atau Netlify	Free tier	CI/CD otomatis; CDN global

13. Limitasi & Rencana ke Depan

13.1 Limitasi Saat Ini

Dataset Bias: CDC BRFSS 2022 adalah survei populasi dewasa Amerika Serikat. Faktor demografis spesifik AS (ras, sistem kesehatan, diet) mungkin tidak sepenuhnya representatif untuk populasi Indonesia. Fitur demografis AS-spesifik (ras) tidak dimasukkan ke form.

Class Imbalance Residual: Precision masih rendah (24.1%) — artinya tingkat false positive cukup tinggi. Dalam konteks screening, ini dapat diterima karena false positive dapat diverifikasi dokter, sementara false negative berbahaya. Namun pengalaman UX pengguna yang sering mendapat "false alarm" perlu dipertimbangkan.

Input Terbatas (10 Fitur): Fitur klinis dengan SHAP importance tinggi (HadAngina #4, HadStroke) tidak ditanyakan untuk alasan UX — pengguna awam sering tidak mengetahui riwayat angina. Nilai di-default ke 0 (tidak ada riwayat), yang konservatif tapi mengurangi akurasi untuk pengguna dengan riwayat klinis yang relevan.

Tidak Ada Validasi Klinis: Model belum divalidasi oleh tenaga medis profesional (dokter spesialis jantung). Tidak ada uji klinis prospektif yang membandingkan hasil Pulsevera dengan diagnosis dokter. Disclaimer "bukan pengganti dokter" harus selalu dipertahankan.

No Longitudinal Data: Dataset BRFSS adalah cross-sectional — tidak dapat melacak perubahan risiko individu dari waktu ke waktu. Pulsevera tidak dapat memberikan analisis "risiko Anda menurun 15% sejak 3 bulan lalu" tanpa fitur history tracking.

13.2 Rencana Pengembangan

Horizon	Inisiatif	Dampak
Short-term (0–3 bulan)	History tracking (opsional, opt-in) Halaman edukasi CVD Optimasi mobile UX	Retensi user; edukasi berkelanjutan
Mid-term (3–6 bulan)	Kolaborasi validasi klinis (FKTP/puskesmas) Dataset Indonesia untuk fine-tuning XGBoost + DL ensemble	Kepercayaan medis; relevansi lokal
Long-term (6–12 bulan)	API integrasi sistem rekam medis (ICD-10) Mobile app (React Native) Kemitraan BPJS program preventif	Dampak sistemik pada kesehatan publik