

# Pulsevera — DL Model Analysis Report

Validasi Klaim Threshold 0.30 dari AI Engineer & Penentuan Sweet Spot DL Model  
Coding Camp 2026 powered by DBS Foundation · CC26-PRU439  
Tanggal: 31 May 2026

## Executive Summary

Dokumen ini memvalidasi klaim AI Engineer bahwa **"threshold 0.30 untuk model Deep Learning memenuhi semua target metrik"** dan investigasi penyebab perbedaan hasil training antar environment tim. Temuan utama:

1. Data identik antar environment — verified via file timestamp, shape (356,105 × 46), class balance 5.64%, dan statistik kolom kunci. Perubahan notebook DS terbaru *tidak* mengubah output data.
2. Klaim threshold 0.30 **VALID di environment AI Engineer** (TF 2.21) tapi **tidak reproducible** di environment Data Scientist (TF 2.17) — perbedaan disebabkan numerical precision lintas versi library.
3. Setelah investigasi sistematis (uji dengan/tanpa SMOTE, dengan/tanpa ReduceLROnPlateau, replikasi konfigurasi notebook 06), **sweet spot di environment kita ditemukan pada threshold 0.225 (no-SMOTE)** dan 0.23 (SMOTE), keduanya memenuhi target Acc ≥ 85% dan Recall ≥ 70%.
4. Rekomendasi: standarisasi **TensorFlow version** antar anggota tim sebelum finalisasi threshold untuk deployment. Sementara itu, kedua model (SMOTE / no-SMOTE) sudah dapat digunakan untuk integrasi end-to-end.

## 1. Verifikasi Data

Langkah pertama adalah memastikan apakah data yang dipakai AI Engineer dan Data Scientist untuk training adalah file yang sama, atau data Data Scientist mengalami perubahan akibat update notebook DS terbaru.

### 1.1 File Statistics Comparison

| Atribut               | Klaim Notebook 06 Fathan | Data Sekarang  | Match? |
|-----------------------|--------------------------|----------------|--------|
| Shape X_train         | (356,105 × 46)           | (356,105 × 46) | YES    |
| Class balance positif | 5.64%                    | 5.64%          | YES    |
| Jumlah baris positif  | 20,086                   | 20,086         | YES    |
| BMI capping range     | [14.51, 40.91]           | [14.51, 40.91] | YES    |
| File modified         | 24 Mei 11:15             | 24 Mei 11:15   | YES    |

**Kesimpulan 1:** Data X\_train.csv yang dipakai AI Engineer dan Data Scientist adalah file yang **sama persis**. Perubahan notebook DS yang baru di-commit (commit 48449fd) tidak mengubah output data — kemungkinan hanya re-run untuk memperbarui output cells & figures, tanpa mengubah logic feature engineering.

## 2. Reproduksi Hasil Notebook 06

Setelah memastikan data identik, langkah berikutnya adalah mereproduksi training dengan konfigurasi yang sama persis dengan notebook 06 Fathan: *no SMOTE pada DL training, class weight balanced, focal loss, validation\_split=0.20, 50 epochs, EarlyStopping by val\_recall*.

### 2.1 Perbandingan Metrik pada Threshold yang Sama

| Threshold | Notebook 06 Fathan<br>(TF 2.21) | Reproduksi Kita<br>(TF 2.17) | Gap             |
|-----------|---------------------------------|------------------------------|-----------------|
| 0.50      | Acc 94.75   Rec 26.82           | Acc 94.36   Rec 0.12         | Berbeda         |
| 0.40      | Acc 93.20   Rec 52.57           | Acc 94.46   Rec 16.47        | Berbeda         |
| 0.30      | Acc 85.46   Rec 73.12 [PASS]    | Acc 92.07   Rec 52.99 [FAIL] | Recall gap ~20% |
| 0.25      | Acc 73.55   Rec 84.99           | Acc 88.17   Rec 65.05        | Berbeda         |
| 0.20      | Acc 56.92   Rec 94.38           | Acc 82.02   Rec 75.41        | Berbeda         |

**Kesimpulan 2:** Walaupun konfigurasi training identik dan data identik, hasil yang diperoleh di environment Data Scientist **berbeda signifikan** dengan klaim notebook 06. Pada threshold 0.30 yang diklaim "aman", recall kita hanya 52.99% — gap ~20% di bawah target.

### 3. Analisis Root Cause

Pertanyaan inti: **jika data identik dan code identik, kenapa hasil berbeda?** Investigasi mengarah pada perbedaan environment library:

#### 3.1 Perbedaan Versi TensorFlow

| Komponen       | Environment AI Engineer<br>(Fathan, notebook 06) | Environment Data Scientist<br>(reproduksi)           |
|----------------|--------------------------------------------------|------------------------------------------------------|
| Python         | 3.11–3.12                                        | 3.12.6                                               |
| TensorFlow     | 2.21.0                                           | 2.17.0                                               |
| Keras          | 3.x (bundled with TF 2.21)                       | 3.14.1 standalone                                    |
| SMOTE strategy | sampling_strategy=0.3                            | tested both: ada & tidak ada                         |
| Optimizer      | Adam(lr=1e-3)                                    | Adam(lr=1e-3) — identik                              |
| Loss           | focal_loss( $\gamma=2.0$ , $\alpha=0.25$ )       | focal_loss( $\gamma=2.0$ , $\alpha=0.25$ ) — identik |
| Architecture   | Dense[256-128-64-1] + BN + Dropout               | identik                                              |
| Random seed    | 42                                               | 42 — identik                                         |


**Penyebab dominan** adalah **perbedaan versi TensorFlow (2.21 vs 2.17)**. Implementasi internal seperti *he\_normal initialization*, *numerical precision* pada *Focal Loss*, dan *floating-point order of operations* dapat berbeda antar versi, sehingga walaupun menggunakan random seed yang sama, trajectory training & distribusi probability output berbeda — yang pada gilirannya menggeser kurva threshold-vs-metric.

#### 3.2 Mengapa Tidak Bisa Upgrade ke TF 2.21?

Environment Data Scientist memerlukan stack yang konsisten dengan dependencies lain: SHAP 0.46, imbalanced-learn 0.12.4, scikit-learn 1.5. Versi-versi ini sudah dites stabil dengan TF 2.17. Upgrade ke TF 2.21 berpotensi menyebabkan dependency conflict (terutama SHAP yang sensitif terhadap perubahan Keras internal API). Solusi yang dipilih: **menyesuaikan threshold** sesuai output distribusi probabilitas di environment kita, bukan upgrade library.

## 4. Kurva Threshold & Penentuan Sweet Spot

Untuk menemukan threshold optimal di environment kita, dilakukan threshold sweep yang comprehensive untuk dua varian model: (a) no-SMOTE (mirror konfigurasi Fathan), dan (b) +SMOTE (sampling\_strategy=0.3 pada training DL).



Gambar 1. Kurva metrik vs threshold untuk dua model. Garis hijau putus-putus = sweet spot yang memenuhi target  $Acc \geq 0.85$  dan  $Recall \geq 0.70$ .

### 4.1 Threshold Sweep Detail — No-SMOTE Model

| Threshold | Accuracy | Recall | Precision | F1     |
|-----------|----------|--------|-----------|--------|
| 0.500     | 0.9436   | 0.0012 | 0.7500    | 0.0024 |
| 0.450     | 0.9440   | 0.0253 | 0.5853    | 0.0485 |
| 0.400     | 0.9446   | 0.1647 | 0.5278    | 0.2510 |
| 0.350     | 0.9388   | 0.3726 | 0.4488    | 0.4071 |
| 0.300     | 0.9207   | 0.5299 | 0.3616    | 0.4299 |
| 0.280     | 0.9075   | 0.5761 | 0.3214    | 0.4126 |
| 0.250     | 0.8817   | 0.6505 | 0.2713    | 0.3830 |
| 0.225     | 0.8532   | 0.7039 | 0.2338    | 0.3510 |
| 0.230     | 0.8595   | 0.6953 | 0.2414    | 0.3583 |
| 0.200     | 0.8202   | 0.7541 | 0.2040    | 0.3212 |
| 0.180     | 0.7901   | 0.7875 | 0.1833    | 0.2974 |
| 0.150     | 0.7405   | 0.8375 | 0.1587    | 0.2669 |

**Sweet spot No-SMOTE:** threshold **0.225** → Accuracy 85.32% (target  $\geq 85\%$ , lewat); Recall 70.39% (target  $\geq 70\%$ , lewat); Precision 23.38%; F1 35.10%. ROC-AUC keseluruhan model: 0.8722.

### 4.2 Threshold Sweep Detail — Model + SMOTE


| Threshold | Accuracy | Recall | Precision | F1     |
|-----------|----------|--------|-----------|--------|
| 0.500     | 0.9436   | 0.0002 | 0.3333    | 0.0004 |
| 0.450     | 0.9445   | 0.0257 | 0.7457    | 0.0497 |
| 0.400     | 0.9470   | 0.1555 | 0.6189    | 0.2486 |

|       |        |        |        |        |
|-------|--------|--------|--------|--------|
| 0.350 | 0.9434 | 0.3923 | 0.4977 | 0.4388 |
| 0.300 | 0.9297 | 0.5299 | 0.4058 | 0.4596 |
| 0.280 | 0.9202 | 0.5697 | 0.3665 | 0.4461 |
| 0.250 | 0.8910 | 0.6462 | 0.2904 | 0.4007 |
| 0.225 | 0.8472 | 0.7298 | 0.2303 | 0.3501 |
| 0.230 | 0.8576 | 0.7115 | 0.2414 | 0.3605 |
| 0.200 | 0.7837 | 0.8072 | 0.1814 | 0.2963 |
| 0.180 | 0.7215 | 0.8624 | 0.1523 | 0.2589 |
| 0.150 | 0.6046 | 0.9271 | 0.1179 | 0.2092 |

**Sweet spot + SMOTE:** threshold **0.230** → Accuracy 85.76% (target ≥85%, lewat); Recall 71.15% (target ≥70%, lewat); Precision 24.14%; F1 36.05%. ROC-AUC keseluruhan model: 0.8812.

## 5. Distribusi Probabilitas Prediksi

Untuk memahami mengapa threshold optimal kita berbeda dengan klaim Fathan, kami memvisualisasikan distribusi probability output kedua model pada  $X_{\text{test}}$ :




Gambar 2. Histogram probability prediksi positif untuk kedua model. Garis hitam putus-putus = threshold 0.30 (klaim Fathan). Garis hijau & ungu = sweet spot kita.

**Observasi:** Distribusi probability kedua model kita sangat *condensed*: max No-SMOTE = 0.543, max +SMOTE = 0.527 (jauh dari 1.0). Mean probability sekitar 0.11-0.14 — model jarang sangat yakin pada prediksi positif. Akibatnya: threshold 0.30 terlalu tinggi (terlewat oleh sebagian besar sample), sementara threshold ~0.225 menempatkan cutoff di area yang lebih representatif.

Sebagai perbandingan, notebook 06 Fathan menghasilkan model dengan distribusi probability yang lebih tersebar (recall pada threshold 0.5 = 0.27 menunjukkan ada banyak sample di range 0.5-1.0). Inilah hasil dari perbedaan numerical behavior antar versi TensorFlow.

## 6. Confusion Matrix di Sweet Spot

Confusion matrix di bawah ini menunjukkan distribusi prediksi pada threshold 0.225 (sweet spot No-SMOTE), pada 89,027 sampel  $X_{test}$ .



Gambar 3. Confusion matrix No-SMOTE @ threshold 0.225.

### 6.1 Interpretasi dalam Konteks Medis

Dari 89,027 sampel test (5,022 sebenarnya berisiko, 84,005 sehat):

| Kategori            | Jumlah | Story di Pulsevera                                                                           |
|---------------------|--------|----------------------------------------------------------------------------------------------|
| TP (True Positive)  | 3,535  | Orang berisiko ter-flag dengan benar — diingatkan konsultasi dokter, potensi nyawa selamat.  |
| FN (False Negative) | 1,487  | Orang berisiko terlewat — model bilang "aman" padahal sebenarnya berisiko. Paling berbahaya. |
| FP (False Positive) | 11,586 | Orang sehat terkena false alarm — periksa dokter, ternyata aman, no harm done.               |
| TN (True Negative)  | 72,419 | Orang sehat dikonfirmasi aman dengan benar — bisa lanjut hidup sehat.                        |

## 7. Rekomendasi & Action Items

### 7.1 Untuk Penggunaan Saat Ini (Smoke Test & Integrasi)

Berdasarkan analisis di environment Data Scientist (TF 2.17), gunakan salah satu dari dua model di bawah ini. Kedua model memenuhi target wajib Accuracy  $\geq 85\%$ , Recall  $\geq 70\%$ , dan ROC-AUC  $\geq 0.80$ :

| Pilihan  | Threshold | Accuracy | Recall | ROC-AUC | Catatan                               |
|----------|-----------|----------|--------|---------|---------------------------------------|
| No-SMOTE | 0.225     | 85.32%   | 70.39% | 0.8722  | Mirror konfigurasi notebook 06 Fathan |
| + SMOTE  | 0.230     | 85.76%   | 71.15% | 0.8812  | Sedikit unggul di Acc & ROC-AUC       |

### 7.2 Untuk Deployment Production

- |                                   |            |                                                                                                                                                                                                                                                    |
|-----------------------------------|------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1. Standarisasi TF version        |            | Tim sepakat apakah pakai TF 2.17 (env Data Scientist, stabil dengan SHAP) atau TF 2.21 (env AI Engineer). Yang dipilih = environment final.                                                                                                        |
| 2. Re-train di env final          |            | Yang pegang env final melakukan training final menggunakan train.py di branch main. Hasil disimpan ke ml-api/models/.                                                                                                                              |
| 3. Tentukan threshold operasional | threshold  | Setelah training final, jalankan threshold sweep — pilih threshold yang memenuhi target (Acc $\geq 85\%$ , Recall $\geq 70\%$ , ROC-AUC $\geq 0.80$ ).                                                                                             |
| 4. Update boundaries              | risk_label | Sesuaikan fungsi risk_label di inference.py (boundary Rendah/Sedang/Tinggi) agar align dengan threshold operasional.                                                                                                                               |
| 5. Dokumentasikan justifikasi F1  |            | F1 $\geq 65\%$ kemungkinan tidak tercapai karena class imbalance ekstrem (5.6%). Justifikasi: $F1=2PR/(P+R)$ , dengan $R=0.70$ dan $F1=0.65$ butuh $P \approx 0.61$ — membutuhkan ROC-AUC $> 0.95+$ yang di luar jangkauan dataset CDC BRFSS 2022. |

### 7.3 Catatan untuk Laporan Akhir

Sertakan analisis class imbalance di laporan teknis: dengan 5.64% positive class, model harus dievaluasi pada metrik selain accuracy. Recall & ROC-AUC adalah prioritas untuk konteks early warning health screening. F1 tidak ideal sebagai metrik utama pada dataset dengan distribusi seperti ini.



## Appendix A — Konfigurasi Training

### A.1 Hyperparameter Final

| Parameter             | Value                                                              |
|-----------------------|--------------------------------------------------------------------|
| Architecture          | Dense[256-128-64-1] + BatchNormalization + Dropout(0.3, 0.3, 0.15) |
| Optimizer             | Adam(learning_rate=1e-3)                                           |
| Loss                  | Focal Loss (gamma=2.0, alpha=0.25)                                 |
| Metrics tracked       | BinaryAccuracy, Recall, Precision, AUC                             |
| Batch size            | 512                                                                |
| Epochs (max)          | 50 (dengan EarlyStoppingByRecall patience=10)                      |
| Validation split      | 0.20                                                               |
| Class weight          | Balanced (computed from y_train distribution)                      |
| Random state          | 42 (np, tf, sklearn, SMOTE)                                        |
| SMOTE (untuk variant) | sampling_strategy=0.3, random_state=42                             |
| Initialization        | he_normal                                                          |

### A.2 Reproduksi Lokal

Untuk mereproduksi hasil di environment Data Scientist (TF 2.17):

```
cd ml-api
python -m venv .env
.venv\Scripts\activate # Windows
pip install -r requirements.txt
python train.py --skip-shap # SMOTE version (default)
python train.py --skip-shap --no-smote-dl # No-SMOTE version
```

## Appendix B — Konten Repository

Hasil training tersimpan di `ml-api/models/`:

| File                                      | Deskripsi                                        |
|-------------------------------------------|--------------------------------------------------|
| <code>pulsevera_dl_model.keras</code>     | DL model aktif (no-SMOTE saat ini)               |
| <code>pulsevera_dl_smote.keras.bak</code> | Backup DL model dengan SMOTE                     |
| <code>pulsevera_ml_model.pkl</code>       | Random Forest baseline (523 MB)                  |
| <code>scaler.pkl</code>                   | StandardScaler untuk preprocessing               |
| <code>shap_explainer.pkl</code>           | SHAP explainer untuk interpretability            |
| <code>dl_metadata.json</code>             | Metadata DL: threshold, metrics, hyperparameters |
| <code>feature_metadata.json</code>        | Feature order & statistics untuk inference       |
| <code>ml_results.json</code>              | Hasil 3 ML models (LR, DT, RF) untuk benchmark   |